Machine Learning

Parte 2

Evandro J.R. Silva

ejrs.profissional@gmail.com

Bacharelado em Ciência da Computação Faculdade Estácio Teresina

23 de julho de 2022



Sumário

- Principais Algoritmos
- Naive Bayes

- k-NN
- Árvore de Decisão





Aprendizado Supervisionado

Aprendizado Não Supervisionado



- Aprendizado Supervisionado
 - Classificação

Regressão



- Aprendizado Supervisionado
 - Classificação
 - Naive Bayes



- Aprendizado Supervisionado
 - Classificação
 - Naive Bayes
 - k-NN



- Aprendizado Supervisionado
 - Classificação
 - Naive Bayes
 - k-NN
 - Árvore de Decisão



- Aprendizado Supervisionado
 - Classificação
 - Naive Bayes
 - k-NN
 - Árvore de Decisão
 - Redes Neurais Artificiais



Aprendizado Supervisionado

Regressão



Aprendizado Supervisionado

- Regressão
 - Regressão Logística



Aprendizado Supervisionado

Aprendizado Não Supervisionado



Aprendizado Supervisionado

- Aprendizado Não Supervisionado
 - k-Means





- Naive Bayes é um modelo de classificação baseado na probabilidade condicional.
- A partir da Teoria da Decisão Bayesiana, podemos calcular, para uma dada observação, qual sua classe mais provável.



- Naive Bayes é um modelo de classificação baseado na probabilidade condicional.
- A partir da Teoria da Decisão Bayesiana, podemos calcular, para uma dada observação, qual sua classe mais provável.
 - Classe ou categoria. Daí vem o termo classificação. A partir de um ou mais atributos podemos separar objetos em diferentes classes.



Lembremos dos peixes:



Figura: Salmão





Figura: Robalo

- A tarefa: classificar um peixe como Salmão ou Robalo.
 - Classes: $\omega_1 = Robalo$
- $\omega_2 = Salmão$.



- A tarefa: classificar um peixe como Salmão ou Robalo.
 - Classes: $\omega_1 = Robalo$

 $\omega_2 = Salmão$.

A priori não se sabe a qual espécie o peixe pertence.



- A tarefa: classificar um peixe como Salmão ou Robalo.
 - Classes: $\omega_1 = Robalo$
- $\omega_2 = Salmão$.
- A priori não se sabe a qual espécie o peixe pertence.
- O brilho do peixe foi observado.



■ Probabilidade a priori

- Reflete o quão verossímil é observar uma das duas espécies de peixe.
- Se a quantidade de Salmão é igual à quantidade de Robalo, então é igualmente verossímil observar um Salmãou ou um Robalo. Portanto:



Probabilidade a priori

- Reflete o quão verossímil é observar uma das duas espécies de peixe.
- Se a quantidade de Salmão é igual à quantidade de Robalo, então é igualmente verossímil observar um Salmãou ou um Robalo. Portanto:
- $P(\omega_1)$: probabilidade *a priori* de se observar um Robalo.



Probabilidade a priori

- Reflete o quão verossímil é observar uma das duas espécies de peixe.
- Se a quantidade de Salmão é igual à quantidade de Robalo, então é igualmente verossímil observar um Salmãou ou um Robalo. Portanto:
- $P(\omega_1)$: probabilidade *a priori* de se observar um Robalo.
- $P(\omega_2)$: probabilidade *a priori* de se observar um Salmão.



Regra de Decisão



- Regra de Decisão
 - Informação disponível: probabilidades a priori.



- Regra de Decisão
 - Informação disponível: probabilidades a priori.

■ Decisão =
$$\begin{cases} \omega_1, & \text{se} \\ \omega_2, & \text{senão} \end{cases} P(\omega_1) > P(\omega_2)$$



■ Regra de Decisão

- Informação disponível: probabilidades a priori.
- Decisão = $\begin{cases} \omega_1, & \text{se} \\ \omega_2, & \text{senão} \end{cases} P(\omega_1) > P(\omega_2)$
- Se $P(\omega_1) \gg P(\omega_2)$, a decisão a favor de ω_1 estará correta a maior parte do tempo.



■ Regra de Decisão

- Informação disponível: probabilidades a priori.
- Decisão = $\begin{cases} \omega_1, & \text{se} & P(\omega_1) > P(\omega_2) \\ \omega_2, & \text{senão} \end{cases}$
- Se $P(\omega_1) \gg P(\omega_2)$, a decisão a favor de ω_1 estará correta a maior parte do tempo.
- Se $P(\omega_1) = P(\omega_2)$, essa decisão tem apenas 50% de chance de estar correta.



Probabilidade Condicional



- Probabilidade Condicional
 - Suponha conhecidas



- Probabilidade Condicional
 - Suponha conhecidas
 - As probabilidades a priori $P(\omega_i)$



- Probabilidade Condicional
 - Suponha conhecidas
 - As probabilidades a priori $P(\omega_i)$
 - As densidades condicionais $p(x|\omega_j), j = 1, 2$



- Probabilidade Condicional
 - Suponha conhecidas
 - As probabilidades a priori $P(\omega_i)$
 - As densidades condicionais $p(x|\omega_j), j = 1, 2$
 - Suponha que o valor observador do brilho foi x.



Probabilidade Condicional

- Suponha conhecidas
 - As probabilidades a priori $P(\omega_i)$
 - As densidades condicionais $p(x|\omega_i), j = 1, 2$
- Suponha que o valor observador do brilho foi x.
- Como isso deve influenciar a nossa decisão em relação a que classe o peixe pertence?



Probabilidade Condicional

- Suponha conhecidas
 - As probabilidades a priori $P(\omega_i)$
 - As densidades condicionais $p(x|\omega_i), j = 1, 2$
- Suponha que o valor observador do brilho foi x.
- Como isso deve influenciar a nossa decisão em relação a que classe o peixe pertence?
 - Densidade de probabilidade conjunta: $p(\omega_i, x)$



■ Teorema de Bayes

$$p(\omega_{j}, x) = P(\omega_{j}|x)p(x) = p(x|\omega_{j})P(\omega_{j})$$

$$\vdots$$

$$P(\omega_{j}|x) = \frac{p(x|\omega_{j})P(\omega_{j})}{p(x)}$$



■ Teorema de Bayes $p(\omega_j, x) = P(\omega_j | x)p(x) = p(x | \omega_j)P(\omega_j)$ \vdots $P(\omega_j | x) = \frac{p(x | \omega_j)P(\omega_j)}{p(x)}$

■ Em palavras: $posteriori = \frac{\text{verossimilhança} \times priori}{\text{evidência}}$





- Posteriori
 - Observando-se x pode-se passar da probabilidade a priori $P(\omega_i)$ para a probabilidade a posteriori $P(\omega_i|x)$.



- Observando-se x pode-se passar da probabilidade a priori $P(\omega_i)$ para a probabilidade *a posteriori* $P(\omega_i|x)$.
- $P(\omega_i|x)$: probabilidade da classe ser ω_i dado que observou-se x.



- Observando-se x pode-se passar da probabilidade a priori $P(\omega_i)$ para a probabilidade *a posteriori* $P(\omega_i|x)$.
- $P(\omega_i|x)$: probabilidade da classe ser ω_i dado que observou-se x.
- Verossimilhança



- Observando-se x pode-se passar da probabilidade a priori $P(\omega_i)$ para a probabilidade a posteriori $P(\omega_i|x)$.
- $P(\omega_j|x)$: probabilidade da classe ser ω_j dado que observou-se x.
- Verossimilhança
 - Indica que a classe ω_j para o qual $p(x|\omega_j)$ é maior, é mais verossímil ser a verdadeira classe.



- Observando-se x pode-se passar da probabilidade a priori $P(\omega_i)$ para a probabilidade a posteriori $P(\omega_i|x)$.
- $P(\omega_j|x)$: probabilidade da classe ser ω_j dado que observou-se x.
- Verossimilhança
 - Indica que a classe ω_j para o qual $p(x|\omega_j)$ é maior, é mais verossímil ser a verdadeira classe.
- Evidência



- Observando-se x pode-se passar da probabilidade a priori $P(\omega_i)$ para a probabilidade a posteriori $P(\omega_i|x)$.
- $P(\omega_j|x)$: probabilidade da classe ser ω_j dado que observou-se x.
- Verossimilhança
 - Indica que a classe ω_j para o qual $p(x|\omega_j)$ é maior, é mais verossímil ser a verdadeira classe.
- Evidência
 - Fator de escala que garante que a soma das probabilidades a posteriori é igual a 1.



- Classificador
 - A partir dos cálculos probabilísticos uma regra de decisão tem de ser escolhida.



- A partir dos cálculos probabilísticos uma regra de decisão tem de ser escolhida.
- Uma bastante comum é escolher a hipótese mais provável, de forma a minimizar a probabilidade de erro de classificação.



- A partir dos cálculos probabilísticos uma regra de decisão tem de ser escolhida.
- Uma bastante comum é escolher a hipótese mais provável, de forma a minimizar a probabilidade de erro de classificação.
- Essa regra é conhecida como máximo a posteriori.



- A partir dos cálculos probabilísticos uma regra de decisão tem de ser escolhida.
- Uma bastante comum é escolher a hipótese mais provável, de forma a minimizar a probabilidade de erro de classificação.
- Essa regra é conhecida como máximo a posteriori.
- $\hat{y} = \underset{k \in \{1, \dots, K\}}{\operatorname{argmax}} p(C_k) \prod_{i=1}^n p(x_i | C_k)$



- A partir dos cálculos probabilísticos uma regra de decisão tem de ser escolhida.
- Uma bastante comum é escolher a hipótese mais provável, de forma a minimizar a probabilidade de erro de classificação.
- Essa regra é conhecida como *máximo a posteriori*.

$$\hat{y} = \underset{k \in \{1,...,K\}}{\operatorname{argmax}} p(C_k) \prod_{i=1}^n p(x_i|C_k)$$

- ŷ: classificação/resultado;
- argmax: argumento máximo, ou seja, o maior valor;
- K: quantidade de classes, ou seja, K classes.
- C_k : classe k, em que k = 1, ..., K;
- $p(C_k)$: probabilidade da classe k;
- $p(x_i|C_k)$: probabilidade da observação x_i dada a classe k;
- n: quantidade de observações.




Exemplo

- Usuários costumam avaliar designs preliminares de produtos. Anteriormente, 95% dos produtos de alto sucesso receberam boas notas, 60% dos produtos de sucesso moderado receberam boas notas, e 10% dos produtos de baixo sucesso receberam boas notas. Além disso, 40% dos produtos tiveram alto sucesso, 35% tiveram sucesso moderado e 25% tiveram baixo sucesso.
 - (a) Qual a probabilidade de um produto ter uma boa nota?
 - (b) Se um novo desing recebe uma boa nota, qua é a probabilidade de que ele venha a ter um alto sucesso?
 - (c) Se um produto n\u00e3o tem uma boa nota, qual \u00e9 a probabilidade de ele vir a ter um alto sucesso?



Exemplo

- A = Alto sucesso
- M = Médio sucesso
- **B** = Baixo sucesso;
- N = Nota boa
- N' = Nota ruim





Resolução

- (a) Probabilidade de um produto ter uma boa nota P(N) = P(N|A)P(A) + P(N|M)P(M) + P(N|B)P(B) = 0,615
- **(b)** Probabilidade de ter um alto sucesso se receber nota boa $P(A|N) = \frac{P(N|A)P(A)}{P(N)} = 0,618$
- (c) Probabilidade de ter um alto sucesso se receber nota ruim $P(A|N') = \frac{P(N'|A)P(A)}{P(N')} \rightarrow P(N')$? P(N') = P(N'|A)P(A) + P(N'|M)P(M) + P(N'|B)P(B) = 0,385 \therefore P(A|N') = 0,052




Aprendizado Supervisionado Classificação

k-NN




- k-NN = k *Nearest Neighbors* ou k Vizinhos Mais Próximos.
- A estimação é baseada na probabilidade a posteriori.






- k-NN = k Nearest Neighbors ou k Vizinhos Mais Próximos.
- A estimação é baseada na probabilidade a posteriori.





P(vermelho) = 2/5 : P(preto) = 3/5

k é um número que pode variar





■ Como *observar* a vizinhança?



- Como observar a vizinhança?
 - Distância Euclidiana (mais comum)



- Como observar a vizinhança?
 - Distância Euclidiana (mais comum)
 - Distância = $\sqrt{\sum_{i=1}^{d}(p_i-q_i)^2}$



- Como *observar* a vizinhança?
 - Distância Euclidiana (mais comum)
 - Distância = $\sqrt{\sum_{i=1}^{d} (p_i q_i)^2}$
 - **Exemplo:** $a_1 = (1, 1)$; $a_2 = (4, 5)$ Distância $(a_1, a_2) = \sqrt{(1 - 4)^2 + (1 - 5)^2}$ Distância $(a_1, a_2) = \sqrt{9 + 16} = 5$



- Como *observar* a vizinhança?
 - Distância Euclidiana (mais comum)

■ Distância =
$$\sqrt{\sum_{i=1}^{d} (p_i - q_i)^2}$$

Exemplo:
$$a_1 = (1, 1)$$
; $a_2 = (4, 5)$
Distância $(a_1, a_2) = \sqrt{(1 - 4)^2 + (1 - 5)^2}$
Distância $(a_1, a_2) = \sqrt{9 + 16} = 5$

Depois de calcular a distância de um ponto a todos os outros, é possível saber quem são os mais próximos, e suas classes.






Segundo Mitchell [1] Árvore de Decisão é um método para aproximação de funções com valores discretos, onde a função aprendida é representada por uma árvore de decisão.



- Segundo Mitchell [1] Árvore de Decisão é um método para aproximação de funções com valores discretos, onde a função aprendida é representada por uma árvore de decisão.
- Algoritmos mais recentes permitem a criação de árvores de decisão com valores contínuos.




- Representação/Visualização de uma árvore
 - Exemplo retirado de [2]





■ Termos técnicos de uma árvore





Evandro J.R. Silva Estácio Teresina

■ Como construir?



- Como construir?
- Ideia base:



- Como construir?
- Ideia base:
 - Escolher um atributo;



- Como construir?
- Ideia base:
 - Escolher um atributo;
 - Estender a árvore adicionando um ramo para cada valor do atributo;



- Como construir?
- Ideia base:
 - Escolher um atributo;
 - Estender a árvore adicionando um ramo para cada valor do atributo;
 - Passar os exemplos para as folhas (tendo em conta o valor do atributo escolhido);



- Como construir?
- Ideia base:
 - Escolher um atributo:
 - Estender a árvore adicionando um ramo para cada valor do atributo;
 - Passar os exemplos para as folhas (tendo em conta o valor do atributo escolhido);
 - 4 Para cada folha



- Como construir?
- Ideia base:
 - Escolher um atributo;
 - Estender a árvore adicionando um ramo para cada valor do atributo;
 - Passar os exemplos para as folhas (tendo em conta o valor do atributo escolhido);
 - 4 Para cada folha
 - Se todos os exemplos são da mesma classe, associar essa classe à folha:



- Como construir?
- Ideia base:
 - Escolher um atributo;
 - Estender a árvore adicionando um ramo para cada valor do atributo;
 - Passar os exemplos para as folhas (tendo em conta o valor do atributo escolhido);
 - 4 Para cada folha
 - Se todos os exemplos são da mesma classe, associar essa classe à folha:
 - Senão, repetir os passos 1 a 4.



Como construir?

Como escolher o melhor atributo?



- Como escolher o melhor atributo?
 - Um atributo deve ser o mais discriminante possível!



Evandro J.R. Silva Estácio Teresina

- Como escolher o melhor atributo?
 - Um atributo deve ser o mais discriminante possível!
 - Uma divisão, a partir de um atributo, que mantem as proporções de classes nas folhas é inútil.



- Como escolher o melhor atributo?
 - Um atributo deve ser o mais discriminante possível!
 - Uma divisão, a partir de um atributo, que mantem as proporções de classes nas folhas é inútil.
 - Já uma divisão que tem como resultado todos os exemplos de uma folha sendo da mesma classe, tem utilidade máxima.



- Algoritmo ID3 (Inductive Decision Tree [3])
 - Para escolher o melhor atributo, é feito um cálculo estatístico conhecido como ganho de informação.



- Algoritmo ID3 (Inductive Decision Tree [3])
 - Para escolher o melhor atributo, é feito um cálculo estatístico conhecido como ganho de informação.
 - $G(S,A) \equiv Entropia(S) \sum_{v \in Valores(A)} \frac{|S_v|}{|S|} Entropia(S_v)$



- Algoritmo ID3 (Inductive Decision Tree [3])
 - Para escolher o melhor atributo, é feito um cálculo estatístico conhecido como ganho de informação.
 - $G(S,A) \equiv Entropia(S) \sum_{v \in Valores(A)} \frac{|S_v|}{|S|} Entropia(S_v)$
 - Conjunto de todos os possíveis valores para o atributo A;



- Algoritmo ID3 (Inductive Decision Tree [3])
 - Para escolher o melhor atributo, é feito um cálculo estatístico conhecido como ganho de informação.
 - $G(S,A) \equiv Entropia(S) \sum_{v \in Valores(A)} \frac{|S_v|}{|S|} Entropia(S_v)$
 - Conjunto de todos os possíveis valores para o atributo A;
 - Subconjunto de S para o qual o atributo A tem valor v;



- Algoritmo ID3 (Inductive Decision Tree [3])
 - Para escolher o melhor atributo, é feito um cálculo estatístico conhecido como ganho de informação.
 - $G(S,A) \equiv Entropia(S) \sum_{v \in Valores(A)} \frac{|S_v|}{|S|} Entropia(S_v)$
 - Para entender essa fórmula, vamos ver seus elementos.



- Algoritmo ID3 (Inductive Decision Tree [3])
 - Para escolher o melhor atributo, é feito um cálculo estatístico conhecido como ganho de informação.

$$G(S,A) \equiv Entropia(S) - \sum_{v \in Valores(A)} \frac{|S_v|}{|S|} Entropia(S_v)$$

- Para entender essa fórmula, vamos ver seus elementos.
- Começando pela Entropia.



A Entropia é uma medida que caracteriza a pureza ou impureza de um conjunto arbitrário de exemplos [1].



- A Entropia é uma medida que caracteriza a pureza ou impureza de um conjunto arbitrário de exemplos [1].
- Seja um conjunto S contendo duas classes, uma positiva (p_{\oplus} = proporção de exemplos positivos) e uma negativa (p_{\ominus} = proporção de exemplos negativos).



- A Entropia é uma medida que caracteriza a pureza ou impureza de um conjunto arbitrário de exemplos [1].
- Seja um conjunto S contendo duas classes, uma positiva (p_{\oplus} = proporção de exemplos positivos) e uma negativa (p_{\ominus} = proporção de exemplos negativos).
- A entropia de S é: $Entropia(S) \equiv -p_{\oplus}log_2p_{\oplus} - p_{\ominus}log_2p_{\ominus}$ ou $Entropia(S) \equiv \sum_{i=1}^{c} -p_i log_2 p_i$



Exemplo

S = 14 exemplos ... [9+, 5-]



Exemplo

S = 14 exemplos ... [9+, 5-]Entropia(S) = Entropia([9+, 5-])



Exemplo

S = 14 exemplos ... [9+, 5-]
Entropia(S) = Entropia([9+, 5-])
=
$$-(9/14)log_2(9/14) - (5/14)log_2(5/14) = 0,940$$



Exemplo ilustrativo

Dia	Tempo	Temperatura	Umidade	Vento	Jogar
D1	Ensolarado	Quente	Alta	Fraco	Não
D2	Ensolarado	Quente	Alta	Forte	Não
D3	Nublado	Quente	Alta	Fraco	Sim
D4	Chuvoso	Média	Alta	Fraco	Sim
D5	Chuvoso	Frio	Normal	Fraco	Sim
D6	Chuvoso	Frio	Normal	Forte	Não
D7	Nublado	Frio	Normal	Forte	Sim
D8	Ensolarado	Média	Alta	Fraco	Não
D9	Ensolarado	Frio	Normal	Fraco	Sim
D10	Chuvoso	Média	Normal	Fraco	Sim
D11	Ensolarado	Média	Normal	Forte	Sim
D12	Nublado	Média	Alta	Forte	Sim
D13	Nublado	Quente	Normal	Fraco	Sim
D14	Chuvoso	Média	Alta	Forte	Não



Tabela: Exemplos de treino para a decisão de jogar



Exemplo ilustrativo

Dia	Tempo	Temperatura	Umidade	Vento	Jogar
D1	Ensolarado	Quente	Alta	Fraco	Não
D2	Ensolarado	Quente	Alta	Forte	Não
D3	Nublado	Quente	Alta	Fraco	Sim
D4	Chuvoso	Média	Alta	Fraco	Sim
D5	Chuvoso	Frio	Normal	Fraco	Sim
D6	Chuvoso	Frio	Normal	Forte	Não
D7	Nublado	Frio	Normal	Forte	Sim
D8	Ensolarado	Média	Alta	Fraco	Não
D9	Ensolarado	Frio	Normal	Fraco	Sim
D10	Chuvoso	Média	Normal	Fraco	Sim
D11	Ensolarado	Média	Normal	Forte	Sim
D12	Nublado	Média	Alta	Forte	Sim
D13	Nublado	Quente	Normal	Fraco	Sim
D14	Chuvoso	Média	Alta	Forte	Não



Tabela: Exemplos de treino para a decisão de jogar



Exemplo ilustrativo

Dia	Tempo	Temperatura	Umidade	Vento	Jogar
D1	Ensolarado	Quente	Alta	Fraco	Não
D2	Ensolarado	Quente	Alta	Forte	Não
D3	Nublado	Quente	Alta	Fraco	Sim
D4	Chuvoso	Média	Alta	Fraco	Sim
D5	Chuvoso	Frio	Normal	Fraco	Sim
D6	Chuvoso	Frio	Normal	Forte	Não
D7	Nublado	Frio	Normal	Forte	Sim
D8	Ensolarado	Média	Alta	Fraco	Não
D9	Ensolarado	Frio	Normal	Fraco	Sim
D10	Chuvoso	Média	Normal	Fraco	Sim
D11	Ensolarado	Média	Normal	Forte	Sim
D12	Nublado	Média	Alta	Forte	Sim
D13	Nublado	Quente	Normal	Fraco	Sim
D14	Chuvoso	Média	Alta	Forte	Não



Tabela: Exemplos de treino para a decisão de jogar



$$\textit{S} = [9+, 5-] \rightarrow \textit{Entropia} = 0,940$$



Ganho de Informação

$$S = [9+, 5-] \rightarrow \textit{Entropia} = 0,940$$

Atributo: Tempo = [Ensolarado, Nublado, Chuvoso]



Ganho de Informação

$$S = [9+, 5-] \rightarrow Entropia = 0,940$$

Atributo: Tempo = [Ensolarado, Nublado, Chuvoso]

 $S_{Ensolarado} = [2+, 3-];$

Ganho de Informação

$$S = [9+, 5-] \rightarrow Entropia = 0,940$$

Atributo: Tempo = [Ensolarado, Nublado, Chuvoso]

 $S_{Ensolarado} = [2+, 3-];$ $S_{Nublado} = [4+, 0-];$



Ganho de Informação

$$S = [9+, 5-] \rightarrow Entropia = 0,940$$

Atributo: Tempo = [Ensolarado, Nublado, Chuvoso]

 $S_{Ensolarado} = [2+, 3-];$

 $S_{Nublado} = [4+,0-];$

 $S_{Chuvoso} = [3+, 2-];$



Ganho de Informação

$$S = [9+, 5-] \rightarrow Entropia = 0,940$$

Atributo: Tempo = [Ensolarado, Nublado, Chuvoso]

 $S_{Ensolarado} = [2+, 3-];$

 $S_{Nublado} = [4+, 0-];$

 $S_{Chuvoso} = [3+, 2-];$

$$G(S, A) \equiv \textit{Entropia}(S) - \sum_{v \in \textit{Valores}(A)} \frac{|S_v|}{|S|} \textit{Entropia}(S_v)$$



$$S = [9+, 5-] \rightarrow Entropia = 0,940$$

Atributo: Tempo = [Ensolarado, Nublado, Chuvoso]
 $S_{Ensolarado} = [2+, 3-];$
 $S_{Nublado} = [4+, 0-];$

$$S_{Nublado} = [4+,0-];$$

 $S_{Chuvoso} = [3+,2-];$

$$G(S, A) \equiv \textit{Entropia}(S) - \sum_{v \in \textit{Valores}(A)} \frac{|S_v|}{|S|} \textit{Entropia}(S_v)$$

$$G(S, Tempo) \equiv 0,940 - (5/14)Entropia(S_{Ensolarado}) - (4/14)Entropia(S_{Nublado}) - (5/14)Entropia(S_{Chuvoso})$$



$$S = [9+,5-] \rightarrow Entropia = 0,940$$

Atributo: Tempo = [Ensolarado, Nublado, Chuvoso]
 $S_{Ensolarado} = [2+,3-];$
 $S_{Nublado} = [4+,0-];$
 $S_{Chuvoso} = [3+,2-];$

$$G(S, A) \equiv \textit{Entropia}(S) - \sum_{v \in \textit{Valores}(A)} \frac{|S_v|}{|S|} \textit{Entropia}(S_v)$$

$$G(S, Tempo) \equiv 0,940 - (5/14) Entropia(S_{Ensolarado}) - (4/14) Entropia(S_{Nublado}) - (5/14) Entropia(S_{Chuvoso})$$

$$G(S, Tempo) \equiv 0,940 - (5/14)0,971 - (4/14)0 - (5/14)0,971$$



$$S = [9+,5-] \rightarrow Entropia = 0,940$$

Atributo: Tempo = [Ensolarado, Nublado, Chuvoso]
 $S_{Ensolarado} = [2+,3-];$
 $S_{Nublado} = [4+,0-];$
 $S_{Chuvoso} = [3+,2-];$

$$G(S, A) \equiv \textit{Entropia}(S) - \sum_{v \in \textit{Valores}(A)} \frac{|S_v|}{|S|} \textit{Entropia}(S_v)$$

$$G(S, Tempo) \equiv 0,940 - (5/14) Entropia(S_{Ensolarado}) - (4/14) Entropia(S_{Nublado}) - (5/14) Entropia(S_{Chuvoso})$$

$$G(S, Tempo) \equiv 0,940 - (5/14)0,971 - (4/14)0 - (5/14)0,971$$

 $G(S, Tempo) \equiv 0,940 - 0,347 - 0 - 0,347$



Ganho de Informação

$$S = [9+,5-] \rightarrow Entropia = 0,940$$

Atributo: Tempo = [Ensolarado, Nublado, Chuvoso]
 $S_{Ensolarado} = [2+,3-];$
 $S_{Nublado} = [4+,0-];$
 $S_{Chuvoso} = [3+,2-];$

$$G(S, A) \equiv \textit{Entropia}(S) - \sum_{v \in \textit{Valores}(A)} \frac{|S_v|}{|S|} \textit{Entropia}(S_v)$$

$$G(S, Tempo) \equiv 0,940 - (5/14)Entropia(S_{Ensolarado}) - (4/14)Entropia(S_{Nublado}) - (5/14)Entropia(S_{Chuvoso})$$

$$G(S, Tempo) \equiv 0,940 - (5/14)0,971 - (4/14)0 - (5/14)0,971$$

$$G(S, Tempo) \equiv 0,940 - 0,347 - 0 - 0,347$$

$$G(S, Tempo) \equiv 0,246$$

Estácio


Ganho de Informação

Ganho(S, Tempo) = 0,246

Ganho(S, Temperatura) = 0,029

Ganho(S, Umidade) = 0, 151

Ganho(S, Vento) = 0,048





Próximo Atributo

$$S_{Ensolarado} = [D1, D2, D8, D9, D11]$$

$$Ganho(S_{Ensolarado}, Umidade) = 0,970 - (3/5)0 - (2/5)0 = 0,970$$

$$Ganho(S_{Ensolarado}, Temperatura) = 0,970 - (2/5)0 - (2/5)1 - (1/5)0 = 0.570$$

$$Ganho(S_{Ensolarado}, Vento) = 0,970 - (2/5)1 - (3/5)0,918 = 0,019$$



Referências I

- Tom M. Mitchell. Machine Learning. ISBN: 0070428077. McGraw-Hill Science/Engineering/-Math, mar. de 1997.
- Teresa B. Ludermir. Ávores de Decisão: Sistemas Inteligentes. Aula ministrada para o [2] curso de Pós-Graduação em Ciência da Computação, CIn-UFPE. 2012.
- [3] J. R. Quinlan. "Induction of decision trees". Em: Machine Learning 1.1 (1986), pp. 81-106.

